

BỘ KHOA HỌC VÀ CÔNG NGHỆ
Học viện Công nghệ Bưu chính Viễn thông



ĐỀ TÀI

Xây dựng hệ thống Hỏi - Đáp (Q&A) tài liệu học thuật

Học phần
Giảng viên
Lớp
Sinh Viên
Mã SV

Thực tập cơ sở
Kim Ngọc Bách
D23CQCE06-B
Phạm Lê An
B23DCCE003

MỤC LỤC

1.GIỚI THIỆU:	3
2.KIẾN TRÚC TỔNG THỂ CỦA HỆ THỐNG RAG:	4
2.1.Trích xuất PDF.....	5
2.2.Chiến Lược Chunking	5
2.3.Embedding Và Vector Search	7
2.4.Reranking Bằng CrossEncoder.....	8
2.5.PROMPT SYSTEM.....	8
2.6.Host LLMs.....	10
3.BENCHMARK.....	12
3.1.Chất lượng retrieval	12
3.2.Đánh giá chất lượng sinh câu trả lời.....	15
3.3.Inference	16
4. KẾT QUẢ CÀI ĐẶT VÀ THỬ NGHIỆM.....	16
4.1. Môi trường cài đặt và cấu hình hệ thống	19
4.2. Kết quả đánh giá chất lượng truy xuất.....	19
4.3. Kết quả đánh giá chất lượng sinh câu trả lời.....	19
4.4. Hiệu năng hệ thống	19
5.KẾT LUẬN VÀ HƯỚNG PHÁT TRIỂN.....	16
5.1. Kết quả đạt được	19
5.2. Hạn chế còn tồn tại	19
5.3.Hướng phát triển trong tương lai.....	19

1. Giới thiệu:

- Hệ thống Q&A được nhóm nghiên cứu và xây dựng nhằm giải quyết một nhu cầu cấp thiết và phổ biến của người dùng khi tiếp cận các bài báo khoa học. Thông thường, người đọc không chỉ cần một bản tóm tắt nội dung khái quát, mà còn mong muốn đặt ra các câu hỏi chuyên sâu về bài toán, phương pháp luận, tập dữ liệu đánh giá (benchmark), kết quả thực nghiệm, cũng như sự khác biệt của công trình đó so với các nghiên cứu trước đây. Để đáp ứng được điều này, hệ thống phải thực hiện song song hai nhiệm vụ phức tạp: truy xuất chính xác đoạn văn bản chứa bằng chứng từ tệp PDF và diễn giải thông tin đó bằng ngôn ngữ tự nhiên, dễ tiếp cận.
- Kiến trúc hiện tại của hệ thống được vận hành chủ yếu dựa trên các công cụ mã nguồn mở và chạy nội bộ. Cụ thể, mô hình local được triển khai qua Ollama. Quá trình nhúng dữ liệu (embedding) sử dụng nomic-embed-text, cơ chế tìm kiếm vector (vector search) được xử lý thông qua FAISS, quá trình sắp xếp lại ngữ cảnh (reranking) dựa trên BAAI/bge-reranker-base và nhiệm vụ sinh ngôn ngữ tự nhiên được giao cho qwen3.5:4b.
- Hệ thống Agent Q&A được thiết kế xoay quanh các tiêu chí cốt lõi sau:
 - **Grounded answering:** Mọi câu trả lời sinh ra đều phải có nền tảng từ nội dung của PDF. Hệ thống không được phép lạm dụng tri thức bên ngoài nếu không có bằng chứng cụ thể trong tài liệu.
 - **Local-first:** Toàn bộ hệ thống có khả năng hoạt động độc lập trên máy tính cá nhân. Điều này không chỉ giúp giảm bớt sự phụ thuộc vào các dịch vụ đám mây mà còn tăng cường tính bảo mật nội dung của tài liệu.
 - **Vietnamese interaction:** Mặc dù phần lớn tài liệu học thuật được viết bằng tiếng Anh, hệ thống vẫn hỗ trợ người dùng nhập truy vấn và nhận phản hồi hoàn toàn bằng tiếng Việt.
 - **Explainability:** Tính minh bạch được đảm bảo khi hệ thống trả về chính xác bằng chứng theo từng trang hoặc đoạn chunk để người dùng có thể dễ dàng đối chiếu và kiểm chứng độ tin cậy.

- Q&A Agent được thiết kế quanh sáu mục tiêu:

Mục tiêu	Ý nghĩa
Grounded answering	Câu trả lời phải dựa trên nội dung PDF, không dựa vào tri thức ngoài nếu không có bằng chứng.
Local-first	Hệ thống có thể chạy trên máy cá nhân, giảm phụ thuộc dịch vụ cloud và bảo vệ nội dung tài liệu.
Vietnamese interaction	Người dùng hỏi và nhận câu trả lời bằng tiếng Việt, trong khi paper thường viết bằng tiếng Anh.
Explainability	Hệ thống nên trả về bằng chứng theo trang/chunk để có thể kiểm tra lại.

2. Kiến Trúc Tổng Thể Của Hệ Thống RAG:

* Pipeline tổng quát của hệ thống có thể mô tả như sau:

- Với đầu vào là PDF paper

- > Chuẩn hóa PDF thành markdown
- > chunking theo đầu mục
- > embedding các chunk
- > FAISS vector index
- > query embedding
- > Lấy top 6 chunk đưa vào rerank
- > cross-encoder reranking top 4
- > System prompt gồm : history, chunk, prompt
- > Đẩy system prompt vào Qwen 3.5 4B

2.1.Trích xuất PDF

- PDF học thuật có tiêu đề, abstract, cột, bảng, công thức, caption, tài liệu tham khảo và đôi khi có layout hai cột. Nếu chỉ extract text thô, hệ thống dễ mất cấu trúc logic của paper. Vì vậy, hệ thống hiện tại dùng cách extraction hướng đến LLM: chuyển PDF thành Markdown theo từng trang.

Đặc điểm	Lợi ích
Heading	Giữ được dấu hiệu section như Introduction, Method, Experiments.
Paragraph	Giữ được đơn vị ý nghĩa tự nhiên.
Table-like text	Có cơ hội bảo tồn bảng kết quả hoặc danh sách dataset.
Page boundary	Mỗi chunk có thể gắn với trang để làm citation.

2.2.Chiến Lược Chunking

Trong một hệ thống RAG (Retrieval-Augmented Generation), phân mảnh dữ liệu (chunking) không đơn thuần là kỹ thuật chia nhỏ chuỗi văn bản một cách cơ học, mà là bước định hình "đơn vị tri thức" cốt lõi mà hệ thống có thể hiểu và truy xuất. Đối với tài liệu học thuật – nơi thông tin có tính liên kết logic cực kỳ cao – một chiến lược chunking tồi sẽ phá hủy hoàn toàn khả năng trả lời của hệ thống.

Bài toán đánh đổi (Trade-off) trong kích thước phân mảnh

Thiết kế hệ thống phải đối mặt với một sự đánh đổi lớn khi lựa chọn kích thước chunk:

- Nguy cơ khi chunk quá nhỏ: Nếu đơn vị phân mảnh quá ngắn, đoạn văn bản sẽ bị tước đoạt mất ngữ cảnh bao quanh. Khi đó, đoạn văn bản chỉ chứa các từ khóa rời rạc mà không mang đủ ý nghĩa trọn vẹn, khiến LLM (mô hình ngôn ngữ) không có đủ dữ kiện để tổng hợp thành một câu trả lời chính xác.
- Nguy cơ khi chunk quá lớn: Nếu nhồi nhét quá nhiều thông tin vào một chunk, vector nhúng (embedding) đại diện cho chunk đó sẽ bị "pha

loãng". Các ý chính bị chìm lấp giữa hàng loạt thông tin rác, khiến công cụ tìm kiếm vector search không thể đo lường chính xác mức độ tương đồng. Hậu quả là quá trình truy xuất (retrieval) bị suy giảm độ chính xác nghiêm trọng.

Tham số hóa và tối ưu qua kiểm thử Thông qua quá trình thực nghiệm và tinh chỉnh (testing), nhóm đã đi đến quyết định sử dụng cấu hình với hai tham số chủ chốt: `chunk_size = 5000` và `overlap = 1000` (tính theo số lượng ký tự).

- Giới hạn 5000 ký tự (`Chunk_size`): Độ lớn này được đánh giá là ngưỡng tối ưu nhất để gói gọn trọn vẹn một luồng ý tưởng, một khái niệm phức tạp hoặc một chứng minh khoa học trong bài báo, giúp bảo tồn tối đa ý nghĩa nguyên bản của tác giả.
- Kỹ thuật chồng lấn 1000 ký tự (`Overlap`): Độ chồng lấn (`overlap`) hoạt động như một "tấm lưới an toàn" nhằm triệt tiêu hiện tượng thất thoát thông tin tại các đường biên cắt. Trong các bài báo khoa học, các luận điểm quan trọng, các công thức toán học hoặc các câu văn dài rất dễ vô tình bị thuật toán cắt làm đôi và nằm ở hai chunk khác nhau. Nhờ có 1000 ký tự chồng lấn lên nhau, hệ thống đảm bảo rằng luận điểm đang bị cắt dở đó chắc chắn sẽ xuất hiện trọn vẹn ở ít nhất một trong hai chunk liền kề. Cơ chế này đóng vai trò then chốt trong việc gia tăng tỷ lệ truy xuất thành công đối với các câu hỏi phức tạp.

Chiến lược tối ưu ngữ nghĩa cho các phân vùng lớn (Semantic Chunking) Đặc thù của các bài báo khoa học là sự xuất hiện của các chương mục vô cùng đồ sộ như *Phương pháp luận (Method)* hay *Kết quả thực nghiệm (Experiment)*. Các chương này có dung lượng vượt quá giới hạn 5000 ký tự, buộc hệ thống phải cắt chúng thành nhiều chunk nhỏ nối tiếp nhau.

Tuy nhiên, việc chia nhỏ này sinh ra một lỗ hổng: các chunk con nằm ở giữa hoặc cuối phần sẽ bị tách rời khỏi tiêu đề (heading) của chương, khiến không gian vector nhúng không nhận diện được chunk đó đang thuộc phần nào của bài báo. Để vá lỗ hổng này, hệ thống áp dụng kỹ thuật *truyền ngữ cảnh (context propagation)*: hệ thống sẽ tự động bắt lấy tiêu đề (heading) tương ứng và chèn (append) ngược lại vào vị trí đầu của mọi chunk con khi chúng bị tách ra. Nhờ sự tối ưu ngữ nghĩa này, dù chunk nằm ở đoạn cuối của phần "Experiment", vector sinh ra vẫn mang theo tín hiệu định hướng rõ ràng, giúp hệ thống không bị nhầm lẫn giữa mô tả phương pháp và diễn giải thực nghiệm.

2.3.Embedding Và Vector Search

- Embedding đóng vai trò là một cầu nối ngữ nghĩa giữa câu hỏi của người dùng và nội dung lưu trữ trong bài báo. Bởi vì người dùng đặt câu hỏi bằng tiếng Việt, trong khi tài liệu gốc được viết bằng tiếng Anh, mô hình embedding có nhiệm vụ chuyển đổi câu hỏi đầu vào thành một không gian vector. Vector này sau đó được đem ra so sánh với các vector chunk để truy xuất ra k vector (với k=6) có độ tương đồng ngữ nghĩa cao nhất.
- Thông số Embedding model nomic-embed-text:

Thuộc tính	Giá trị
Architecture	nomic-bert
Parameters	137M
Context length	2048
Embedding length	768
Quantization	F16
Capability	embedding

- Việc lưu trữ vector được triển khai bằng FAISS.

FAISS phù hợp với bài toán này vì:

- tìm vector gần nhất nhanh;
- chạy local;
- không cần hệ quản trị vector database riêng;
- phù hợp với index theo từng paper;
- dễ cache index để hỏi lại nhiều lần.

2.4.Reranking Bằng CrossEncoder

- Reranking là tăng sắp xếp lại các chunk ứng viên sau vector search. Hệ thống lấy 6 ứng viên ban đầu, sau đó dùng BAAI/bge-reranker-base để chấm điểm từng cặp [question + chunk] → relevance score

Thuộc tính	Giá trị
Architecture	XLNet-RoBERTa-based Cross-Encoder
Parameters	~278M
Context length	512 tokens
Embedding length	Không dùng embedding output
Quantization	FP32 mặc định / có thể chạy FP16
Capabilities	reranking, relevance scoring, retrieval refinement
License	MIT License

- Sau rerank, hệ thống chọn top-4 chunk nhằm xử lý một lỗi rất phổ biến trong RAG là đưa quá nhiều context không cần thiết vào LLM. Khi context bị nhiều, LLM có thể bị phân tâm, trả lời lan man, hoặc tệ hơn là dựa vào nhầm đoạn.

2.5.Prompt System

* Prompt system là lớp điều khiển hành vi của LLM trong Q&A Agent. Trong một hệ thống RAG, prompt không chỉ dùng để hỏi model, mà còn đóng vai trò ràng buộc model phải trả lời dựa trên bằng chứng được truy xuất từ tài liệu. Vì vậy, prompt system là thành phần quan trọng để giảm hallucination, chuẩn hóa ngôn ngữ trả lời và giữ câu trả lời phù hợp với mục tiêu hỏi đáp học thuật.

- Prompt của hệ thống gồm ba phần chính:

1. System prompt: định nghĩa vai trò và nguyên tắc bắt buộc của model.
2. User prompt: đưa context trích xuất từ PDF, lịch sử hỏi đáp gần đây và câu hỏi hiện tại.

3. Generation options: cấu hình hành vi sinh câu trả lời như temperature, context length, số token sinh ra.

- Các ràng buộc chính

+ Prompt của hệ thống đặt các nguyên tắc bắt buộc:

- Chỉ trả lời dựa trên tài liệu: Model không được tự dùng kiến thức ngoài để bổ sung nếu thông tin không nằm trong context.
- Nếu tài liệu không đề cập thì nói rõ: Khi context không có bằng chứng, model phải trả lời rằng tài liệu không đề cập, thay vì đoán.
- Trả lời bằng tiếng Việt: Phù hợp với giao diện và người dùng mục tiêu của hệ thống.
- Giữ thuật ngữ kỹ thuật tiếng Anh: Các thuật ngữ như Transformer, Attention, Loss function, CLIP, Prompt Learning không nên dịch cứng vì dễ làm sai nghĩa.
- Không dùng tiếng Trung: Tránh lỗi một số model Qwen có thể sinh ký tự hoặc câu tiếng Trung trong câu trả lời do model được train rất nhiều trên tiếng Trung.
- Trả lời ngắn gọn nhưng đủ ý: Giảm câu trả lời dài dòng, hạn chế hallucination.
- Định dạng bằng Markdown: Giúp hiển thị rõ ràng bằng bullet, tiêu đề nhỏ, in đậm.

+ Một cấu trúc của prompt system gồm :

-context : các chunk

-memory : lịch sử chat

- câu hỏi từ người dùng

+ Hệ thống cố gắng khắc phục giải pháp loss in middle bằng việc đưa phần memory ít quan trọng hơn vào giữa system prompt

2.6.Host LLMs

- * Ollama được sử dụng trong hệ thống như một **local model runtime** để host các mô hình phục vụ Q&A Agent. Vai trò của Ollama không chỉ là chạy LLM sinh câu trả lời, mà còn cung cấp embedding model cho tầng retrieval. Trong hệ thống hiện tại, Ollama đang đảm nhiệm hai chức năng chính:

1. **Generation**: sinh câu trả lời bằng model qwen3.5:4b.
2. **Embedding**: sinh vector embedding bằng model nomic-embed-text.

Hiện qwen 3.5 4B được quantization với các thông số :

Thuộc tính	Giá trị
Architecture	qwen35
Parameters	4.7B
Context length	262144
Embedding length	2560
Quantization	Q4_K_M
Capabilities	completion, vision, tools, thinking
License	Apache License 2.0

Q&A Agent đưa context vào prompt và gọi Ollama /api/chat để sinh câu trả lời.

- Cấu hình inference trong hệ thống:

Tham số	Giá trị hiện tại trong code
model	qwen3.5:4b

stream	False
think	False
num_ctx	8192
num_predict	4096
temperature	0.1

- Ý nghĩa:

Tham số	Phân tích
temperature=0.1	Giảm tính ngẫu nhiên, phù hợp hỏi đáp học thuật cần chính xác.
num_ctx=8192	Cho phép prompt tương đối dài, nhưng hệ thống hiện vẫn tự cắt context ở 5000 ký tự.
num_predict=4096	Cho phép sinh câu trả lời dài nếu cần, nhưng có nguy cơ verbosity.
think=False	Không yêu cầu model trả về reasoning/thinking trong response.

3. Benchmark

3.1. Chất lượng retrieval

- * Benchmark retrieval đánh giá chất lượng tìm bằng chứng theo mức section. Một query được tính là đúng nếu trong top-4 chunk sau rerank có ít nhất một chunk thuộc nhóm section mong đợi.

- Tập Đánh Giá

Thuộc tính	Giá trị
Số paper	7
Số câu hỏi mỗi paper	5
Tổng truy vấn	35
Papers	CoOp, CoCoOp, CoPrompt, HiCroPL, MaPLe, ProGrad, PromptSRC
Loại câu hỏi	problem, method, dataset, result, comparison

- 5 câu hỏi mỗi paper tương ứng với 5 loại truy vấn đánh giá sau:

Loại câu hỏi	Mục đích hỏi	Ví dụ dạng câu hỏi
problem	Hỏi paper giải quyết bài toán/vấn đề gì	“Paper CoOp giải quyết bài toán gì?”
method	Hỏi phương pháp chính của paper	“Paper CoOp sử dụng phương pháp gì?”
dataset	Hỏi dataset hoặc benchmark dùng để đánh giá	“Paper CoOp dùng dataset/benchmark nào để đánh giá?”
result	Hỏi kết quả thực nghiệm chính	“Thực nghiệm của paper CoOp cho thấy kết quả chính gì?”
comparison	Hỏi điểm khác biệt so với phương pháp trước đó	“Paper CoOp khác gì so với các phương pháp trước đó?”

- Cách Tính Hit@4

- + Hit@4 trả lời câu hỏi:

Trong 4 chunk tốt nhất sau rerank, có ít nhất một chunk thuộc section mong đợi không?

- + Công thức:

$\text{Hit@4} = \text{số query có ít nhất 1 chunk đúng trong top-4} / \text{tổng số query}$

- Cách Tính Hit@1

- + Hit@1 nghiêm ngặt hơn. Nó chỉ kiểm tra chunk đứng đầu sau rerank.
- + Công thức:

$\text{Hit@1} = \text{số query có chunk rank 1 đúng section} / \text{tổng số query}$

Với 35 query:

- Thông số tổng quan

Setting	Hit@1	Hit@4
FAISS + reranker, top-4	45.71%	80.00%

- Thông số trên từng loại câu hỏi

Question type	Hit@4
dataset	7/7
problem	6/7
result	6/7
method	5/7
comparison	4/7

- Thông số trên từng paper

Paper	Hit@4
CoOp	4/5
CoCoOp	3/5
CoPrompt	5/5
HiCroPL	5/5
MaPLe	4/5
ProGrad	2/5
PromptSRC	5/5

- Phân tích:

Loại câu hỏi	Nhận xét
Dataset	Dễ nhất vì query có từ khóa dataset/benchmark, khớp với Experiments/Dataset/Evaluation.
Problem	Khá dễ vì Abstract/Introduction thường diễn đạt trực tiếp bài toán.
Result	Retrieval tương đối tốt, nhưng answer vẫn khó vì cần đọc bảng và số liệu.
Method	Khó hơn vì method có thể có tên riêng hoặc nằm trong section không được đặt tên rõ.
Comparison	Khó nhất vì bằng chứng phân tán giữa Related Work, Introduction, Method và Experiments.

3.2.Đánh giá chất lượng sinh câu trả lời

- Benchmark thứ hai đánh giá answer-level bằng gemini 3.1 pro để so sánh được chất lượng response giữa model local 4B và GPT-5.5.

Tiêu chí	Model 4B	GPT-5.5
Answer Relevancy	0.88	0.96
Correctness / Faithfulness	0.70	0.94
Completeness	0.75	0.92
Conciseness	0.58	0.94
Overall	0.76	0.94

Tiêu chí	Ý nghĩa đánh giá
Answer Relevancy	Đánh giá mức độ liên quan của câu trả lời đối với câu hỏi được đặt ra. Điểm cao khi câu trả lời tập trung vào đúng nội dung cần hỏi và không lạc đề.
Correctness / Faithfulness	Đánh giá tính chính xác của câu trả lời so với nội dung trong paper hoặc ngữ cảnh được cung cấp. Điểm cao khi thông tin đúng và không xuất hiện hallucination.
Completeness	Đánh giá mức độ đầy đủ của câu trả lời. Điểm cao khi câu trả lời bao quát đầy đủ các ý chính cần thiết để trả lời câu hỏi.
Conciseness	Đánh giá tính ngắn gọn và súc tích của câu trả lời. Điểm cao khi câu trả lời rõ ràng, không lan man và không chứa thông tin dư thừa.
Overall	Điểm tổng hợp phản ánh chất lượng chung của câu trả lời dựa trên các tiêu chí đánh giá ở trên.

3.3. Inference

Chỉ số	Giá trị ước tính
Model load size	~3.4 GB
VRAM khi tải model	~3.2 – 3.8 GB
VRAM cực đại khi inference	~4.2 – 5.2 GB
Tốc độ sinh văn bản	~17-25 tokens/s

- Tổng thể thời gian trả lời mỗi câu hỏi ~25-30s

4. Kết quả cài đặt và thử nghiệm

4.1. Môi trường cài đặt và cấu hình hệ thống

Hệ thống được thiết kế theo tiêu chí "Local-first", toàn bộ các mô hình đều được triển khai và vận hành cục bộ trên máy tính cá nhân thông qua runtime Ollama. Việc sử dụng Ollama giúp quản lý hiệu quả tài nguyên và đảm bảo tính bảo mật cho dữ liệu học thuật của người dùng.

Cấu hình các mô hình được sử dụng:

- Mô hình Embedding: Sử dụng nomic-embed-text (kiến trúc nomic-bert, 137M tham số) để chuyển hóa văn bản thành vector.
- Mô hình Reranking: Sử dụng BAAI/bge-reranker-base (kiến trúc XLM-ROBERTa-based Cross-Encoder, ~278M tham số) để chấm điểm và sắp xếp lại các đoạn ngữ cảnh.
- Mô hình Generation (LLM): Sử dụng qwen3.5:4b với tham số lượng tử hóa Q4_K_M để sinh câu trả lời. Cấu hình inference cho mô hình được thiết lập nhằm tối ưu cho tác vụ hỏi đáp học thuật:
 - temperature = 0.1: Giảm tính ngẫu nhiên, giúp câu trả lời mang tính chính xác và nhất quán cao.
 - num_ctx = 8192: Đảm bảo mô hình có đủ không gian ngữ cảnh cho các truy vấn phức tạp.
 - num_predict = 4096: Cho phép sinh câu trả lời đủ dài và chi tiết.

4.2. Kết quả đánh giá chất lượng truy xuất

* Bảng: Chi tiết tỷ lệ Hit@4 theo từng nhóm truy vấn

Loại câu hỏi	Hit@4	Phân tích
Dataset	7/7	Tốt nhất do từ khóa query khớp trực tiếp với section Experiments/Evaluation.
Problem	6/7	Khá dễ vì phần Abstract/Introduction thường diễn đạt trực tiếp bài toán.
Result	6/7	Truy xuất tương đối tốt, nhưng việc LLM đọc hiểu số liệu trong bảng vẫn là thách thức.
Method	5/7	Khó hơn do phương pháp có thể dùng tên riêng hoặc nằm ở các section không rõ tên.
Comparison	4/7	Khó nhất vì bằng chứng thường phân tán rải rác giữa Introduction, Method và Related Work.

4.3.Kết quả đánh giá chất lượng sinh câu trả lời

* Bảng: So sánh điểm đánh giá chất lượng sinh văn bản

Tiêu chí	Điểm Model 4B	Điểm GPT-5.5	Nhận xét	Tiêu chí	Điểm Model 4B
Answer Relevancy	0.88	0.96	Câu trả lời của hệ thống bám sát tốt vào trọng tâm câu hỏi.	Answer Relevancy	0.88
Completeness	0.75	0.92	Cung cấp tương đối đầy đủ các ý chính, tuy nhiên vẫn kém LLM kích thước lớn.	Completeness	0.75
Correctness	0.70	0.94	Thông tin khá chính xác, nhưng thỉnh thoảng vẫn gặp hiện tượng hallucination (ảo giác).	Correctness	0.70

4.4.Hiệu năng hệ thống (Inference Performance)

Hệ thống được thử nghiệm thực tế để đo lường mức độ tiêu thụ tài nguyên phần cứng. Kết quả cho thấy hệ thống rất nhẹ và có thể triển khai trên các máy tính cá nhân phổ thông:

- Dung lượng tải mô hình (Model load size): ~3.4 GB.
- Mức tiêu thụ VRAM khi tải: ~3.2 - 3.8 GB.
- Mức tiêu thụ VRAM cực đại khi sinh chữ: ~4.2 - 5.2 GB.
- Tốc độ sinh văn bản: Đạt khoảng 17 - 25 tokens/giây. Tổng thời gian để hệ thống phản hồi hoàn chỉnh cho một câu hỏi trung bình dao động từ 25 - 30 giây.

5. Kết luận và hướng phát triển

5.1. Kết quả đạt được

- Xây dựng thành công Pipeline RAG hoàn chỉnh: Hệ thống đã tích hợp và vận hành trơn tru chuỗi xử lý từ khâu trích xuất PDF sang Markdown, phân mảnh dữ liệu (chunking) tối ưu với kích thước 5000 ký tự (overlap 1000 ký tự), đến việc nhúng vector và lưu trữ qua FAISS.
- Đảm bảo tiêu chí Local-first và bảo mật dữ liệu: Toàn bộ hệ thống, từ mô hình nhúng (nomic-embed-text), mô hình xếp hạng lại (BAAI/bge-reranker-base) cho đến mô hình sinh ngôn ngữ (qwen3.5:4b) đều được triển khai cục bộ thông qua Ollama. Điều này giúp người dùng hoàn toàn làm chủ dữ liệu bài báo mà không phụ thuộc vào các API bên thứ ba.
- Tối ưu hóa khả năng truy xuất bằng chứng (Retrieval): Việc áp dụng chiến lược reranking bằng Cross-Encoder đã mang lại hiệu quả rõ rệt. Đánh giá trên tập dữ liệu thực tế cho thấy hệ thống đạt độ chính xác Hit@4 lên tới 80.00%, đặc biệt hoạt động cực kỳ chính xác với các truy vấn về tập dữ liệu (Dataset) và bài toán nghiên cứu (Problem).
- Bản địa hóa ngôn ngữ giao tiếp: Xây dựng thành công bộ Prompt System khắt khe, ép buộc LLM tuân thủ việc trả lời bằng tiếng Việt, duy trì tính minh bạch (explainability) bằng cách bám sát ngữ cảnh truy xuất và báo cáo rõ ràng khi không tìm thấy thông tin.

5.2. Hạn chế còn tồn tại

- Giới hạn của mô hình 4B: Dù tối ưu tốt về mặt tài nguyên (chỉ yêu cầu ~5GB VRAM khi inference), mô hình Qwen3.5:4b vẫn bộc lộ điểm yếu trong khả năng suy luận logic phức tạp. Điểm số Conciseness (0.58) và Correctness (0.70) cho thấy câu trả lời đôi khi còn dài dòng, lan man và vẫn tiềm ẩn nguy cơ xuất hiện "ảo giác" (hallucination) khi phải xử lý các bảng biểu và số liệu thống kê phức tạp.
- Xử lý các truy vấn so sánh (Comparison): Khả năng truy xuất bằng chứng phân tán từ nhiều chương mục khác nhau để trả lời các câu hỏi mang tính chất so sánh phương pháp vẫn là một thách thức lớn (chỉ đạt 4/7 Hit@4).

5.3. Hướng phát triển trong tương lai

- Nâng cấp mô hình sinh (Generation Upgrade): Thử nghiệm áp dụng các kỹ thuật lượng tử hóa (quantization) mới hơn để có thể chạy các mô hình lớn hơn (như mô hình 7B hoặc 8B tham số) trên cùng phần cứng, nhằm cải thiện khả năng đọc hiểu và tổng hợp văn bản ngắn gọn, chính xác hơn.
- Tích hợp đồ thị tri thức (GraphRAG): Nghiên cứu áp dụng kiến trúc GraphRAG để lập bản đồ mối quan hệ giữa các thực thể, tác giả, và phương

pháp. Điều này sẽ khắc phục triệt để điểm yếu trong việc trả lời các câu hỏi dạng so sánh (comparison).

- Mở rộng phạm vi tìm kiếm đa tài liệu (Multi-document Q&A): Phát triển hệ thống từ việc chỉ hỏi đáp trên một bài báo đơn lẻ sang khả năng tổng hợp, đối chiếu và tóm tắt thông tin từ một tập hợp nhiều bài báo khoa học liên quan.
- Hoàn thiện giao diện người dùng (UI/UX): Xây dựng một ứng dụng web hoàn chỉnh với giao diện trực quan, cho phép người dùng theo dõi trực tiếp đoạn văn bản gốc (citation highlight) ngay trên khung hiển thị PDF bên cạnh cửa sổ chat.