

Học phần: Thực tập cơ sở

XÂY DỰNG HỆ THỐNG HỎI - ĐÁP (Q&A) TÀI LIỆU HỌC THUẬT

Sinh viên thực hiện: Phạm Lê An | MSSV: B23DCCE003

Giảng viên: TS.Kim Ngọc Bách

GIỚI THIỆU VẤN ĐỀ

- Các bài báo khoa học (paper) thường dài và phức tạp, khó đọc toàn bộ
- Người dùng mong muốn hỏi trực tiếp thay vì đọc hàng chục trang tài liệu
- Cần một hệ thống Q&A có độ chính xác cao, trả lời dựa trên nội dung tài liệu gốc



MỤC TIÊU HỆ THỐNG

1

Grounded Answering

Trả lời dựa hoàn toàn trên tài liệu gốc, không tự suy diễn hay hallucination ngoài ngữ cảnh.

2

Local-first

Vận hành offline, không phụ thuộc đám mây. Bảo mật dữ liệu và hoạt động độc lập hoàn toàn.

3

Vietnamese Interaction

Giao tiếp và trả lời bằng tiếng Việt, phù hợp với người dùng học thuật trong nước.

4

Explainability

Giải thích được nguồn gốc câu trả lời, trích dẫn đoạn context liên quan từ tài liệu gốc.

5

Độ chính xác cao

Sử dụng Reranking (Cross Encoder) để lọc context, đạt Hit@4 = 80% trên bộ dữ liệu đánh giá.

6

Dễ sử dụng

Giao diện đơn giản: upload PDF, đặt câu hỏi và nhận câu trả lời ngay lập tức.

KIẾN TRÚC PIPELINE HỆ THỐNG

Giai đoạn 1

PDF Extraction & Chunking
 PDF Paper →
→ Markdown
→ Chunking
(5000/1000)
→ Semantic Chunks
→ Heading Append

Giai đoạn 2

Embedding & Retrieval
 Chunks →
→ Embedding
→ FAISS Vector DB
→ Top-6 Retrieval
→ Cross Encoder
Reranking
→ Top-4 Context

Giai đoạn 3

LLM Answer Generation
 System Prompt
• Memory + Context
• User Question
• → Qwen3.5-4B
(Ollama)
• → Answer (Tiếng Việt)

PDF EXTRACTION + CHUNKING

PDF → Markdown

Trích xuất nội dung từ file PDF học thuật sang định dạng Markdown có cấu trúc.

- Giữ nguyên Heading (H1, H2, H3)
- Bảo toàn Paragraph và nội dung văn bản
- Giữ thông tin Page number
- Công cụ: PyMuPDF / Marker
- Đầu ra: file .md sạch, có cấu trúc rõ ràng

Chunking

Chia nhỏ văn bản Markdown thành các đoạn (chunk) phù hợp để nhúng vector.

- chunk_size = 5000 ký tự
- overlap = 1000 ký tự
- Semantic chunking theo ngữ nghĩa
- Append heading vào đầu mỗi chunk
- Giữ ngữ cảnh liên tục giữa các chunk

EMBEDDING & RETRIEVAL

Embedding Model

Model sử dụng: nomic-embed-text — chuyên biệt cho văn bản học thuật. Mỗi đoạn văn bản (chunk) được chuyển thành vector 768 chiều. Quá trình: Question / Chunk → Embedding Model → Dense Vector (768d). Hỗ trợ tiếng Việt, chạy hoàn toàn local, không cần kết nối đám mây.

Vector Retrieval

Cơ sở dữ liệu vector: FAISS (Facebook AI Similarity Search) — lưu trữ và tìm kiếm local. Pipeline: User Question → Embedding → Query Vector → FAISS Index → Top-6 Chunks. Độ đo tương đồng: Cosine Similarity. Kết quả Top-6 chunks liên quan nhất được chuyển sang bước Reranking.

RERANKING (TÁI XẾP HẠNG)

Quy trình Reranking

Top-6 Chunks (từ FAISS)
↓
Cross Encoder Scoring
↓
Top-4 Chunks (đã lọc)
Mỗi chunk được chấm điểm độc lập dựa trên mức độ liên quan với câu hỏi.
Chỉ giữ lại 4 chunk có điểm cao nhất làm context cho LLM.

Cross Encoder Model

- Model: BAAI/bge-reranker-base
- Kiến trúc: BERT-based Cross Encoder
 - Input: (câu hỏi, chunk) → điểm liên quan
 - Loại bỏ context nhiễu, không liên quan
 - Nâng cao độ chính xác câu trả lời
 - Chạy hoàn toàn local (offline)
 - Giảm từ Top-6 xuống Top-4 context

PROMPT SYSTEM

Đầu vào LLM

System Prompt + Memory + Retrieved Context + User Question → LLM (Qwen3.5-4B)

- ◆ System Prompt: Định nghĩa vai trò trợ lý, ngôn ngữ tiếng Việt, định dạng Markdown
- ◆ Memory: Lịch sử hội thoại (conversation history)
- ◆ Retrieved Context: Top-4 chunks từ bước Reranking
- ◆ User Question: Câu hỏi của người dùng

Quy tắc Sử dụng

- ✓ Chỉ trả lời dựa trên context được truy xuất — không tự bịa thông tin
- ✓ Phản hồi bằng tiếng Việt, định dạng Markdown rõ ràng
- ✓ Không hallucination: nếu không có thông tin, thông báo rõ ràng
- ✓ Trích dẫn nguồn từ tài liệu gốc khi cần thiết

HOST LLM

- 🖥️ Nền tảng: Ollama — chạy local, offline
- 🤖 Model: Qwen3.5-4B | Dung lượng: 3.4 GB
- 🔧 Embedding: nomic-embed-text
- ⚙️ Thông số kỹ thuật:
 - temperature = 0.1
 - num_ctx = 8192 tokens
 - num_predict = 4096 tokens
- ✅ Không phụ thuộc cloud — bảo mật & ổn định



BENCHMARK RETRIEVAL

1


Hit@1 = 45.71% và Hit@4 = 80%: Đánh giá khả năng truy xuất đúng chunk liên quan trong top-1 và top-4 kết quả trả về từ FAISS.

2

Problem = 60%, Result = 60%: Độ chính xác truy xuất theo loại câu hỏi về vấn đề và kết quả nghiên cứu trong tài liệu học thuật.

3

Method = 50%, Comparison = 40%: Truy xuất phương pháp và so sánh còn hạn chế do đặc thù ngôn ngữ kỹ thuật chuyên sâu.



Nguồn: Dữ liệu do AI tạo. Hãy thay thế hoặc xác minh trước khi sử dụng.

BENCHMARK ANSWER

1


Relevancy: Model 4B đạt 0.88, GPT-5.5 đạt 0.96
Độ liên quan câu trả lời với câu hỏi đặt ra.

2

Correctness & Completeness: 0.70 / 0.75 vs 0.94 / 0.92
Độ chính xác và đầy đủ thông tin trong câu trả lời.

3

Overall Score: Model 4B đạt 0.76, GPT-5.5 đạt 0.94
Đánh giá tổng thể chất lượng hệ thống Q&A.



Nguồn: Dữ liệu do AI tạo. Hãy thay thế hoặc xác minh trước khi sử dụng.

HIỆU NĂNG HỆ THỐNG



Model Size
3.4 GB — nhỏ gọn, dễ triển khai trên máy cá nhân.



VRAM Tiêu Thụ
4.2 – 5.2 GB — phù hợp GPU tầm trung trở lên.




Tốc Độ Sinh Token
17 – 25 tokens/s — phản hồi nhanh, mượt mà.



Thời Gian Phản Hồi
25 – 30 giây cho mỗi câu trả lời đầy đủ.



Môi Trường Vận Hành
Local-first — hoàn toàn offline, không cần đám mây.



Nền Tảng
Ollama + Qwen3.5-4B — dễ cài đặt, hiệu quả cao.

KẾT LUẬN



Đạt Được

- Pipeline RAG hoàn chỉnh từ PDF đến Answer
 - Local-first: vận hành offline, không phụ thuộc đám mây
 - Hit@4 = 80% — độ chính xác retrieval cao
- Hỏi đáp tiếng Việt hiệu quả, tự nhiên
 - Tích hợp Reranking nâng cao chất lượng context
 - Hệ thống nhẹ, chạy được trên máy cá nhân



Hạn Chế

- Model 4B còn nhỏ, khả năng suy luận phức tạp hạn chế
- Điểm Comparison còn thấp (40%)
 - Chưa hỗ trợ đa tài liệu cùng lúc
- Tốc độ phản hồi 25–30s chưa tối ưu
 - Giao diện người dùng chưa hoàn thiện
- Chưa đánh giá trên tập dữ liệu lớn

HƯỚNG PHÁT TRIỂN

Giai đoạn 1

GraphRAG
Áp dụng đồ thị tri thức (Knowledge Graph) để tăng khả năng suy luận đa tài liệu, cải thiện độ chính xác retrieval theo quan hệ ngữ nghĩa.

Giai đoạn 2

7B / 8B Model
Nâng cấp lên model ngôn ngữ lớn hơn (Qwen 7B, LLaMA 8B) để tăng chất lượng trả lời, cải thiện điểm Correctness & Completeness. Multi-document QA: Hỗ trợ hỏi đáp đồng thời trên nhiều tài liệu PDF.

Giai đoạn 3

UI Hoàn Chỉnh
Xây dựng giao diện người dùng đầy đủ: upload PDF, quản lý tài liệu, lịch sử hội thoại, hiển thị nguồn trích dẫn rõ ràng và trực quan.



**THANKS FOR
LISTENING**